


圖 5.14 G 函數曲線。


二、 F 函數

F 函數與 G 函數的概念類似，不過其並非計算事件點兩兩之間的最短距離，而是先產生隨機分布的點位 p_i ，並計算隨機點位最近樣本點的距離，最後再以這些距離繪製累積頻率分布，其公式如下：

$$F(d) = \frac{\#[d(p_i, S) < d]}{n} \quad (5.9)$$

式 5.9 中的 $d(p_i, S)$ 代表隨機選取的地點 p_i 與最近鄰近樣本之間的距離，該公式的分子表示距離小於 d 的隨機點總數。 F 函數的優點是能夠克服 G 函數資料數過少的問題，因為 F 函數在計算過程中可以選取夠多的隨機點來計算距離，使得曲線能夠呈現平滑狀（圖 5.15）。

雖然 G 函數與 F 函數看似在進行類似的計算，然而，其結果卻有很大的差異。當點分布型態為群聚時， G 函數的曲線會在短距離內急速增加，而 F 函數的曲線則是先緩緩上升，隨著距離的增加，曲線再快速地上升，如圖 5.16(a)。當點型態為均勻分布時，情況則相反， G 函數的曲線會在距

圖 5.15 F 函數曲線。

離較大時快速上升，而 F 函數計算所得的距離將會比 G 函數的數值較小，因此上升的也比 G 函數的數值來得快，如圖 5.16(b)。

目前為止所介紹的方法，包括最鄰近分析法、 G 函數及 F 函數，三者都只考慮與最鄰近點之間的距離，然而，這可能會造成某些嚴重的問題，以圖 5.17 為例，當所有的點都與其最鄰近點相近，但與其他事件點都相距甚遠時，利用最鄰近分析法、 G 函數及 F 函數所得到的結果都會是群聚的分布型態，但這卻是錯誤的判斷。

三、Ripley's K 函數

Ripley (1976) 的 **K 函數** 主要目的就是想解決上述的問題。 K 函數的計算方式是以每一個事件點為圓心， d 為半徑畫圓，計算在圓圈內其他事件點的數量，最後取平均後除以分布密度，得到 $K(d)$ 值。為了畫出 K 函數，我們必須重複上述步驟，計算不同 d 值下的 $K(d)$ 數值， K 函數的公式如下：

$$K(d) = \frac{\sum_i \sum_{j \neq i} I(d_{ij} < d)}{N\lambda} \quad (5.10)$$




圖 5.16 G 函數與 F 函數累積頻率曲線比較：(a) 群聚分布；(b) 均勻分布。




圖 5.17 造成最鄰近分析法、 G 函數及 F 函數分析結果誤導的範例。

其中， $I(d_{ij} < d)$ 是一指標函數，若 i, j 兩點距離小於 d 則 $I = 1$ ，否則 $I = 0$ 。 $\sum_i \sum_{j \neq i} I(d_{ij} < d)$ 表示以樣本 i 為圓心， d 為半徑的圓內，所涵蓋的樣本點數量（不包含 i 本身）、 N 為樣本數、 λ 為平均每單位面積包含的樣本數， K 函數的運算示意，如圖 5.18。

K 函數的計算不是只考慮與最鄰近點的距離，而是計算不同距離範圍內所涵蓋的事件點數量。圖 5.19 分別展示兩種分布的 K 函數累積頻率曲線。

圖 5.19(a) 說明的是群聚時的曲線圖，首先曲線會快速上升，因為在短距離內就能夠涵蓋許多事件點，接著會有一段距離內都沒有涵蓋到更多的事件點，因此曲線變平，直到偵測到另外一個群聚時，曲線才又開始快速上升；圖 5.19(b) 說明的是均勻分布的曲線圖，曲線一開始沒有涵蓋到事件點，因此曲線持平，當半徑大到可以涵蓋到下一個事件點時，曲線才會上升。




圖 5.18 K 函數的計算示意圖。




圖 5.19 不同分布型態下的 $K(d)$ 函數：(a) 群聚分布；(b) 均勻分布。

在實際的資料分析中， $K(d)$ 曲線不像上面的範例圖如此易於解釋，因此，我們將 $K(d)$ 結果與獨立隨機過程的期望值比較，以判斷分布的型態。要判定空間型態是否具有統計顯著性，必須定義一個期望值的**信心區間**（confidence interval）。在空間分析的統計檢定，大多應用**蒙地卡羅顯著性檢定**（Monte Carlo significance test）來推論其空間型態。其計算方式是透過蒙地卡羅法以產生多次的隨機模擬，通常是 999 次或者更多，模擬在相同研究區面積與地物數量下的隨機分布，並計算其 K 函數的數值。最後找出這些模擬數據當中，每個搜尋距離所得到的 K 函數第 97.5% 的值與第

2.5% 的值（在 95% 信心水準下），並繪製於圖表中作為信心區的上界與下界（圖 5.20）。

然而，當搜尋距離愈大時，所能搜尋到的地物數量也會增加，使得 K 函數值變得相當大，橫軸縱軸會不斷的增加，因此，減低 K 函數值有助於圖表的繪製與閱讀。常用的修正方式是轉換 K 函數數值，轉換後的函數稱為 L 函數，其函數間的轉換公式如下：

$$L(d) = \sqrt{\frac{K(d)}{\pi}} \quad (5.11)$$

透過 L 函數的計算，在任何搜尋距離下的期望值，就是搜尋距離本身（ d ），故在分析中常計算 $L(d) - d$ 。若該數值在任何搜尋距離下皆為 0，則在圖表中呈現為一條水平線，即為隨機分布。因此，在任何搜尋距離下，只要該數值大於期望值信賴區間的範圍，則偏向群聚分布，如圖 5.21(a)；反之，則偏向隨機分布，如圖 5.21(b)。




圖 5.20 K 函數：觀察值、期望值及 95% 信賴區間的上、下界。




圖 5.21 不同地物分布型態的 L 函數：(a) 群聚分布；(b) 隨機分布。

四、邊緣效應及其校正方法

在所有計算距離的方法中，都會面臨一個相同的問題：邊緣效應。邊緣效應是指當事件點發生在研究區的邊緣時，其與最鄰近點間的距離往往較大，然而事實上，在研究區的外面可能有另一事件點更靠近它，使得我們高估了該事件點與最鄰近點的距離，如圖 5.22。

圖 5.22 中有數個位於邊緣的事件點，分別都與數個在邊緣外的事件點相距較近，但這些點因不在研究區內而不會被計算到，造成了結果的錯誤。




圖 5.22 橢圓範圍的點位於緊鄰研究區外圍的區域，使研究區內的分析結果可能被低估。

要解決這種錯誤結果的方法之一，可以利用 K 函數的環域距離，沿著研究區邊緣向外產生一個環域，將位於環域內的事件點一併納入計算（圖 5.23）。

若未取得研究區以外的資料，則可在研究區邊緣向內產生一個環域，縮小研究區的範圍（圖 5.24），並將環域內的事件點視為邊緣事件並納入計算。

由於 K 函數不像 F 函數及 G 函數只考慮點跟點的距離關係，而是藉由樣本中心圓計算包含到的樣本數。 K 函數的計算牽涉到面與點的關係，因此其邊緣校正方法也與前兩者不同。經邊緣校正的 K 函數公式如下：

$$K(d) = \frac{\sum_i \sum_{j \neq i} w(l_i l_j)^{-1} (d_{ij} < d)}{N\lambda} \quad (5.12)$$




圖 5.23 向外擴大研究區以包含造成邊緣效應的地物。




圖 5.24 向內縮小研究區以剔除會產生邊緣效應的地物。

與原公式的差別僅有分子的 $w(l_i, l_j)$ 代表邊緣校正權重， $w(l_i, l_j)$ 為樣本 i 為中心圓包含在研究區內的比例，例如：若該圓完全在研究區內，則

$w(l_i, l_j) = 1$ ，亦即不需要進行邊緣校正；若該圓只有一半的面積位於研究區內，則 $w(l_i, l_j) = 0.5$ ，即假設有一半的樣本被忽略，因此校正時，將原本計算所得的圓內樣本數乘上 2 倍。